



激光与光电子学进展
Laser & Optoelectronics Progress
ISSN 1006-4125, CN 31-1690/TN

《激光与光电子学进展》网络首发论文

题目: 基于卷积神经网络的室内可见光指纹定位方法
作者: 许浩, 王旭东, 吴楠
收稿日期: 2020-11-18
网络首发日期: 2021-01-20
引用格式: 许浩, 王旭东, 吴楠. 基于卷积神经网络的室内可见光指纹定位方法[J/OL]. 激光与光电子学进展.
<https://kns.cnki.net/kcms/detail/31.1690.TN.20210120.1033.010.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于卷积神经网络的室内可见光指纹定位方法

许浩, 王旭东*, 吴楠

(大连海事大学信息科学技术学院 辽宁 大连 116026)

摘要 为进一步提高室内可见光定位系统性能,提出了一种基于卷积神经网络(Convolutional Neural Network, CNN)的可见光指纹定位方法。该方法利用参考节点 LED 的光强信号作为特征,构建指纹数据库,将接收器坐标作为训练标签,引入一维卷积神经网络学习模型进行训练,建立基于光强信息的定位模型。卷积神经网络的应用,较好地解决了全连接前馈神经网络定位精度低、稳定性差的问题。在室内 $5\text{m}\times 5\text{m}\times 3\text{m}$ 的定位场景下,利用提出的定位算法可以获得平均定位误差 4.44cm 的定位精度。通过仿真实验,对比分析了不同室内可见光定位算法的性能,验证了本文算法的技术优势。

关键词 光通信; 室内定位; 卷积神经网络; 指纹定位; 接收信号强度

中图分类号 TN929.1 **文献标识码** A

Indoor Visible Light Fingerprint Positioning Scheme Based on Convolution Neural Network

Xu Hao, Wang Xudong*, Wu Nan

(Information Science Technology College, Dalian Maritime University, Dalian 116026, China)

Abstract In order to further improve the performance of indoor visible light positioning systems, an visible light fingerprint positioning scheme based on Convolutional Neural Network (CNN) is proposed. In this scheme, optical intensity signals of LED of the reference node and the receiver coordinates are used to build a fingerprint database and the train labels respectively. Moreover, a one-dimensional convolutional neural network learning model is adopted for training and a positioning model in terms of light intensity information is constructed. The application of convolutional neural network has solved the problems of low positioning accuracy and poor stability of the fully connected feedforward neural network. In the indoor positioning scene of $5\text{m}\times 5\text{m}\times 3\text{m}$, the proposed positioning scheme can obtain high positioning accuracy with the average positioning error of 4.44cm . Through simulation experiments, the performance of several different indoor visible light positioning algorithms is compared and analyzed, and also the technical advantages of the proposed algorithm is verified.

Key words optical communications; indoor positioning; convolutional neural network; fingerprint positioning; received signal strength

OCIS codes 060.4510; 230.3670; 230.5160

1. 引言

基金项目: 国家自然科学基金(61371091)

E-mail: xhhr@dlmu.edu.cn; *E-mail: wxd@dlmu.edu.cn; E-mail:alfred.nan.wu@gmail.com

随着互联网的发展和智能终端设备的日益普及，基于定位的服务（Location Based Service, LBS）^[1]逐渐受到人们的关注。为了实现室内的精确定位，近年出现了一些通过增加其他的外部硬件或设施来提高室内定位精度的方法，例如超宽带定位、蓝牙定位、射频识别定位和无线 Wi-Fi 定位系统等^[2-5]。但却存在增加定位辅助设施困难，硬件安装成本较高且不易扩展，以及存在严重的多径效应及电磁干扰等诸多问题。随着可见光通信技术（Visible Light Communications, VLC）^[6]的不断发展，可见光定位（Visible Light Positioning, VLP）^[7-8]以定位成本低、不受电磁干扰和多径效应影响、定位安全性高等特点获得学术和业界的高度关注。

目前，可见光室内定位技术得到了迅速发展。传统的可见光室内算法主要有到达时间法（Time of Arrival, TOA）、到达时间差法（Time Difference of Arrival, TDOA）^[9]、到达角度法（Angle of Arrival, AOA）^[10]、接收信号强度法（Received Signal Strength, RSS）^[11]和指纹匹配法^[12-13]等。此外，还可以用数码相机代替光电检测（Photodetector, PD）器件直接根据捕获的图像来获取坐标位置^[14]。随着定位技术的深入研究，逐渐衍生和发展出了各种具有更高复杂度的室内可见光定位算法，其中包括有混合定位算法和基于机器学习的定位算法等。文献[15]提出了一种基于 RSS/AOA 混合可见光定位算法，该算法利用最小二乘法建立混合目标函数，将目标函数转换成广义信赖域子问题求解位置坐标，获得在 5m×5m×3m 定位场景下的 8.7cm 的平均精度。文献[16]提出了一种基于 k-means 聚类的无监督 LED 定位算法，首次将机器学习方法引入到可见光室内定位系统中，其使用由两个 LED 组成的发射端，接收端则是通过测量不同位置的光强度来构建稀疏网络最后计算得出信号强度。最终在 4.3m×4m×4m 的场景中接收器的平均定位误差可达 0.31m。k-means 聚类方法对 K 值的选取敏感，很难确定分成几类是最佳。同时，噪声的存在会影响类的选取，难以实现高精度定位。文献[17]将支持向量机(Support Vector Machine, SVM)引入到室内可见光定位算法中，主要是从机器学习角度研究指纹定位算法，并结合机器学习架构来解决指纹定位中出现的问题，与传统的指纹定位方法相比，平均定位精度提高了 40%。支持向量机方法对大规模训练样本难以实施，选取的定位点增多，定位精度很显著下降。同时，支持向量机对参数跟核函数选择敏感，核函数的选取问题还尚未得到解决。文献[18]在传统的指纹定位的基础上引入了人工神经网络，用训练过的神经网络再进行定位，可在散射信道环境下实现精确定位，在 5m×5m×3m 的场景中测量平均定位误差达到了 6.39cm。全连接神经网络中神经元全部连接，会使参数增多并容易引入误差量，导致定位精度下降。

为进一步提高基于可见光信号强度信息的指纹定位算法的性能，提出了一种基于 CNN 的室内可见光指纹定位方法。构建 4 个 LED 发射器作为定位参考节点，接收端采用 PD 作为接收器接收光功率的定位系统结构。离线阶段通过在接收平面随机选取多个采样点来训练一维卷积神经网络（Conv 1D），实现基于光强指纹的定位模型。在线阶段将测量的信号强度 RSS 数据输入到卷积神经网络模型定位中，实现高精度位置估计。利用仿真实验，在 $5\text{m} \times 5\text{m} \times 3\text{m}$ 的室内环境下，通过对比分析，验证了所提算法的可行性和提高定位精度的有效性，以及算法所具备的良好收敛性和泛在性。

2. 定位模型与定位过程

2.1 系统模型

设定室内定位场所为 $5\text{m} \times 5\text{m} \times 3\text{m}$ 的实验区域，系统模型如图 1 所示。接收端采用光电检测器件接收光强信号，定位时，接收端根据接收到的信号强度信息，进行位置估计。将作为发射端的照明设备 LED 安装于房间的天花板处，这样来自不同 LED 光照形成的辐射区能彼此重叠，以此来确保平面内的任意一个定位点都能够同时接收到不同 LED 所发出的光照信息。考虑到室内 LED 的实际布置情况，采用 4 个 LED 作为发射端，选择正方形拓扑。设定发射端 LED 编号为 Tx_i ($i=1 \dots 4$)，其中 $Tx_i=[x_i, y_i, z_i]$ ，各 LED 坐标为 $Tx_1(1.25, 1.25, H)$ 、 $Tx_2(1.25, 3.75, H)$ 、 $Tx_3(3.75, 1.25, H)$ 、 $Tx_4(3.75, 3.75, H)$ ； H 为天花板到接收平面的垂直高度。只考虑二维空间定位，待定位点可位于地面上的任意位置，坐标为 $\mathbf{x}(\mathbf{x} \in \mathbb{R}^2)$ ，其中 $\mathbf{x}=[x, y]$ 。




图 1 可见光定位系统模型
Fig.1 The system model of visible light positioning

2.2 信道模型

可见光定位系统选取 LED 作为信号发射源，引入 Lambertian 辐射模型，直射链路（Line of Sight, LOS）信道的直流增益可表示为：

$$H(0) = \frac{(m+1)}{2\pi d^2} A \cos^m(\phi) T_s(\psi) g(\psi) \cos(\psi), \quad (1)$$

$$0 \leq \psi \leq \psi_{\text{FOV}},$$

式中： m 为朗伯系数， $m = -\ln 2 / \ln(\cos \phi_{1/2})$ ， $\phi_{1/2}$ 是 LED 的半功率角。 d 为发射端 LED 到接收端 PD 的距离， A 为 PD 的接收面积， ϕ 为发射端的辐射角， ψ 为接收端的入射角， $g(\psi)$ 为聚光器增益， $T_s(\psi)$ 为光滤波器增益， ψ_{FOV} 为聚光器的视场角。

在 VLP 系统中， LED 发出光信号， 通过 LOS 信道到达接收端的信号可表示为：

$$y(t) = H(0) \cdot x(t) + n(t) \quad (2)$$

其中， $n(t)$ 接收到的噪声。 通常建模为热噪声与散粒噪声。 假设不考虑 LOS 信道中码间干扰的影响， N 为噪声方差总和， 可表示为

$$N = \sigma_{\text{shot}}^2 + \sigma_{\text{thermal}}^2 \quad (3)$$

散粒噪声方差可表示为

$$\sigma_{\text{shot}}^2 = 2qRP_{\text{rSignal}}B + 2qI_{\text{bg}}I_2B \quad (4)$$

其中 I_{bg} 表示背景光产生的暗电流， q 表示电子电荷量， I_2 表示噪声带宽系数， B 表示为等效噪声带宽。

热噪声方差表示为

$$\sigma_{\text{thermal}}^2 = \frac{8\pi kT_k}{G} C_{\text{pd}} A I_2 B^2 + \frac{16\pi^2 kT_k \Gamma}{g_m} C_{\text{pd}}^2 A^2 I_3 B^3 \quad (5)$$

其中 T_k 为热力学温度， k 为玻尔兹曼常数， C_{pd} 为光电检测器单位面积电容， G 为开环电压增益， g_m 为跨导系数， Γ 为场效应管信道噪声系数。

位于第 i 个测量位置接收到的 4 个 LED 灯发出的光功率可表示为：

$$P_i = [p_{i1}, p_{i2}, p_{i3}, p_{i4}] \quad (6)$$

2.2 指纹库构建

离线阶段构建指纹数据库， 在接收平面上每隔 u 米采样， 将接收平面划分为 N 个 $u \times u$ 的网格。 记录每个网格的位置坐标作为标签向量， 位置坐标可表示为 (x_i, y_i) ， $i=1, \dots, N$ 。 通过采集每个网格点上接收到的来自不同 LED 的 RSS 信息来构成指纹库的特征向量， 接收信号强度向量可表示为 $P_i = [p_{i1}, p_{i2}, p_{i3}, p_{i4}]$ 。 这样每一个位置坐标都有一组对应的接收信号强度向量， 以此来形成一条指纹数据构建指纹库， 如表 1 所示。

表 1 指纹数据库

Tab. 1 Fingerprint database

Reference point	Coordinate		Received signal strength			
1	x_1	y_1	p_{11}	p_{12}	p_{13}	p_{14}
2	x_2	y_2	p_{21}	p_{22}	p_{23}	p_{24}
3	x_3	y_3	p_{31}	p_{32}	p_{33}	p_{34}
...
N	x_N	y_N	p_{N1}	p_{N2}	p_{N3}	p_{N4}

2.3 定位过程

所提出的基于 CNN 的定位算法分为两个阶段：在线阶段和离线阶段。离线阶段，在定位区域内均匀选取若干个参考点，记录每个参考点的接收信号强度（RSS）和对应的位置坐标来构建指纹库，将 RSS 作为特征输入、位置坐标作为标签，来训练卷积神经网络模型。在线阶段，测量待测位置的 RSS 值，并输入到训练好的卷积神经网络中，计算输出待测点位置坐标。

3. 基于 CNN 的指纹定位方法

3.1 数据归一化

在我们提出的算法中，输入数据是来自不同 LED 的接收强度信息。为了更好的训练数据并加速卷积神经网络收敛，我们将输入数据进行均值归一化（Mean normalization）处理，给予原始数据的均值和标准差进行数据的标准化。经过处理的数据符合均值为 0，标准差为 1 的标准正态分布，转化函数为：

$$P_n' = \frac{P_n - \mu}{\sigma} \quad (7)$$

其中 N 为样本数总数， $\mu = \frac{1}{N} \sum_{n=1}^N P_n$ 为所有样本数据的均值， $\sigma = \frac{1}{N} \sum_{n=1}^N (P_n - \mu)^2$ 为所有样本数据的标准差。 P_n' 则是归一化样本数据，可以作为输入数据输入到卷积神经网络中。

3.2 卷积神经网络结构

所提出的算法采用一维卷积神经网络，网络结构如图 2 所示，由卷积层，池化层，平坦层及全连接层四个部分组成。

卷积层：使用随机初始化滤波器来提取输入数据的特征。随着卷积神经网络的卷积层数增多，会有梯度消失和梯度爆炸的风险。为了将输入数据的所有特征全部提取出来，经过仿真实验多次调试，发现使用 3 个卷积层足以保证网络的学习能力。第一个卷积层使用 128 个滤波器，卷积核大小为 2，步长设置为 1；第二和第三个卷积层分别使用 64、32 个滤波器，

卷积核大小和步长与第一层卷积层相同。此外为了将从输入数据中提取的局部特征的大小保持不变，每个卷积层都采用零填充。

池化层：将从卷积层输出的特征压缩，起到子采样的作用。本文采用最大池化法（Max Pooling），以提取滑动窗口中的最大值进行子采样。池化层窗口大小为 2，步长为 2，在这种情况下，输出维数减小为原来的一半，既减少了时间复杂度又防止了过拟合。

平坦层：把多维的输入一维化，用在池化层与全连接层之间过渡，将池化层的 32×2 个输出转化为 64 个输出以便于全连接层相连。

全连接层：将卷积层和池化层输出的特征做非线性组合，用于预测最终位置。




图 2 卷积神经网络模型

Fig.2 Convolution neural network model

卷积神经网络的输入是 PD 接收到的来自 4 个 LED 的光功率向量，输出为 PD 所对应的位置坐标。则卷积层第 l 层的第 m ($1 \leq m \leq M$) 个特征输出可以表示为：

$$Z^{(l,m)} = f(W^{(l,m)} \otimes P^{(l-1)} + b^{(l,m)}) \quad (8)$$

其中 $W^{(l,m)}$ 和 $b^{(l,m)}$ 为卷积核和偏置。第 l 层中共有 M 个卷积核和 M 个偏置。 $P^{(l-1)}$ 上一层的输入。

池化层对卷积层的输出 Z_i 的 K 个区域进行子采样，得到池化层的输出为 $Y=\{y_k\}$ ，其中：

$$y_k = \max_{i \in R_k} \{Z_i\} \quad (9)$$

设每个全连接层的权重和偏置分别为 $W^{(l,j)}$ 和 $b^{(l,j)}$ ，设第 $l-1$ 层全连接层的神经元个数为 q ，则当前全连接层第 l 层中第 j 个神经元的输出为：

$$X^{(l,j)} = f\left(\sum_{t=1}^q W^{(l,t,j)} Y^{(l-1,t)} + b^{(l,j)}\right) \quad (10)$$

常见的激活函数主要有 Relu、tanh 与 sigmoid 函数。其中 tanh 与 sigmoid 函数两端饱和，容易导致神经网络梯度消失的问题，并且权重更新缓慢。而 Relu 函数的神经元只需要进行加、乘和比较的操作，能够减少计算量，并且避免产生梯度消失的问题。同时，采用 Relu 函数能加快网络收敛，提高效率。所提出的 CNN 结构中，每个神经元的激活函数都使用 Relu，即有：

$$Relu(x) = \begin{cases} 0 & x < 0 \\ x & x \geq 0 \end{cases} \quad (11)$$

为了解决卷积神经网络过拟合的问题，加入 dropout 层。其中过度拟合是指由于样本数据训练得太准确而导致实际使用中精度太低的情况。我们在每个全连接层之后都使用了 dropout 层。dropout 率设置为 0.2，即从全连接网络中随机舍弃掉 20% 的神经元，来防止过拟合，提高预测精度。

为了训练卷积神经网络，使其产生更准确的预测值，引入损失函数。其通常作为学习准则，即通过最小化损失函数求解和评估卷积神经网络模型。而回归问题最常用的损失函数是均方误差 MSE，定义如下：

$$MSE(y, \hat{y}) = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n} \quad (12)$$

式中： y_i 为一个 batch 中第 i 个数据的位置坐标，而 \hat{y}_i 为神经网络给出的预测值。

4. 定位仿真结果与分析

4.1 优化算法

根据前面所提出的定位模型，在 $5m \times 5m \times 3m$ 的室内场景中进行仿真。信道仿真参数如表 2 所示。先将定位区域划分为 676 个 $0.2m \times 0.2m$ 的网格，该区域内收集每个网格接收到的来自 4 个 LED 的接收信号强度及每个网格对应的位置坐标作为指纹来建立指纹数据库。为了评估定位模型的性能，定义均方根误差（RMSE）函数为：

$$RMSE = \sqrt{E[(x - \hat{x})^2 + (y - \hat{y})^2]} \quad (13)$$

式中 $E[\cdot]$ 为统计平均运算符；在二维平面内对定位算法进行误差分析，不考虑定位点高度，则 (x, y) 为定位点的真实坐标； (\hat{x}, \hat{y}) 为定位点的估计坐标。

此外，利用 1660tiGPU 的计算机对提出的定位算法进行仿真验证，并使用 Python-3.6.6 在 Keras-2.3.1（Tensorflow-gpu-2.1.0）上训练深度学习模型。

表 2 信道仿真参数

Tab.2 Parameters used in channel simulation

Parameter	Value	Parameter	Value
Transmitted optical power(P_t)	1W	Absolute temperature(T_K)	300K
Fied of view(FOV)	60°	Dark current(I_{bg})	5100μA
Semi-angle at half power($\phi_{1/2}$)	70°	Open-circuit voltage gain (G)	10

Refractive index (n)	1.5	FET transconductance (g_m)	30mS
Wall reflectivity (ρ)	80%	Noise bandwidth factor (I_2)	0.562
Gain of optical filter(T_s)	1	Noise bandwidth factor (I_3)	0.0868
Modulation bandwidth(B)	100MHz	Noise factor (F)	1.5

为了优化网络模型、提升定位性能，选取不同的优化算法做比较。在仿真实验中，在定位区域内均匀选取 2601 个 $0.1\text{m} \times 0.1\text{m}$ 的参考点，对每个点进行位置估计。使用多种优化算法并改变其学习率来优化网络结构，其中包括 Adam，SGD，Rmsprop。不同优化算法的实验结果如图 3 所示。可以看出，使用不同优化器和学习率对定位性能影响很大。大多数优化器可以将定位误差降至 6cm 以内。而当 Adam 优化算法为 0.001 时，对位置估计误差最低。并且 Adam 优化算法提供了快速而可靠的学习收敛，比同类优化算法（例如 SGD、Rmsprop 等）要快得多。选取 Adam 优化算法来训练卷积神经网络，学习率为 0.001。




图 3 不同学习率下各种优化器对定位性能的影响

Fig.3 The effect of various optimizers with different learning rates on positioning errors

4.2 定位实验

(1) 定位误差分布

确定好网络模型，并选取最优的激活函数与优化算法。对定位区域内均匀选取的 2601 个 $0.1\text{m} \times 0.1\text{m}$ 的参考点进行位置估计，得到基于 CNN 定位算法的误差分布。图 4 为定位误差空间分布图，其平均定位误差为 4.44cm，最大定位误差为 25.12cm；图 5 为定位误差分布直方图，可以看出大部分定位误差都分布在 10cm 以内，验证了算法的可行性。




图 4 定位误差空间分布

Fig.4 The spatial distribution of positioning error




图 5 定位误差概率直方图

Fig.5 Histogram of positioning error probability

(2) 与 BP 神经网络算法性能比较

为了说明提出的算法网络结构的优越性,将提出的算法与基于多层全连接的 BP 神经网络算法做比较。离线阶段,将指纹库中的数据训练神经网络模型,其中随机选取指纹库中的数据取 20%作为验证数据 (Validation data),评估两种网络模型准确率,结果如图 6 所示。可以看出,所提出的网络模型较好的收敛性。对定位区域内选取的 2601 个点测量并比较定位误差,每种算法重复进行 5 次仿真实验,结果如图 7 所示。可以看出,随着实验次数的增加,提出的算法定位误差大小几乎不变,维持在 5cm 以内。而基于多层全连接 BP 神经网络定位算法的误差波动很大,最大平均定位误差接近 8cm。说明提出算法的网络结构具有稳定性。图 8 给出了两种算法的累积分布函数 (Cumulative Distribution Function, CDF) 曲线。所提出算法的 CDF 曲线左移,所提出算法与基于多层全连接 BP 神经网络算法在 95%置信区间的定位误差分别为 10.5cm、14.1cm。提出的算法误差小,定位性能优于基于多层全连接 BP 神经网络的算法。在多层全连接 BP 神经网络中,每个隐藏层中的神经元与上一层的神经元是全连接状态,权重矩阵的参数非常多,训练效率会非常低。同时,训练参数多会导致参数中很容易引入误差量。卷积神经网络具有局部连接和权重共享的特点,用卷积神经网络来代替全连接 BP 网络,能减少参数数量并降低模型的复杂度。




图 6 不同网络模型训练误差比较

Fig.6 Comparison of training errors in different network models




图 7 不同网络模型定位误差比较

Fig.7 Comparison of positioning errors




图 8 不同网络模型累计概率分布比较

Fig.8 Comparison of CDF in different network models

(3) 与传统算法性能比较

为了进一步证明所提出算法定位的有效性, 改变测试点数量, 在实验场景内每隔 0.7m 均匀选取 64 个点来测试提出算法的性能。图 9 给出了所提出算法的 64 个估计点以及参考点位置。同时, 我们选取传统的 RSS 三边法 (Trilateral method) 和其他两种机器学习方法即基于支持向量机 (SVM) 的定位算法及基于决策树 (Decision Tree) 的定位算法与我们提出的基于 CNN 的定位算法相比较, 结果如图 10 所示。支持向量机是深度学习出现之前, 在机器学习中表现最好的算法。决策树易于实现, 短时间可以对大量数据做出良好的结果, 效率高。表 3 给出了 4 种不同定位算法的定位误差, 可以看出, 所提出定位算法的最大定位误差、平均定位误差都比其他三种定位算法小很多, 说明所提出的基于 CNN 定位算法性能更好。与传统的三边定位法相比, 所提出的算法平均定位误差减少了 64.4%, 最大定位误差减小了 69.5%。与基于 SVM 的定位算法相比, 所提出的算法平均定位误差减少了 41.9%, 最大定位误差减少了 45.8%。与基于决策树的定位算法相比, 所提出的算法平均定位误差减少了 43.4%, 最大定位误差减少了 40.9%。图 11 比较了不同算法累计分布曲线, 所提出的算法 CDF 曲线左移, 并且可以看出, 所提出的算法、基于 SVM 的定位算法、基于决策树的

定位算法及传统三边法在 95%置信区间的定位误差分别为 10.50cm、15.66cm、19.70cm、56.52cm。




图 9 算法定位结果

Fig.9 The final positing results

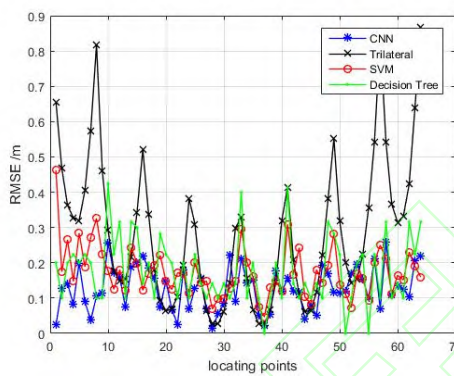


图 10 不同算法定位误差比较

Fig.10 Comparison of positioning errors

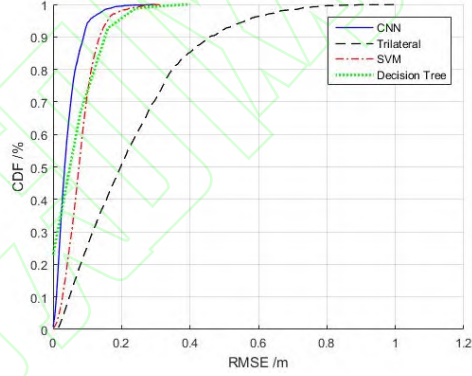


图 11 不同算法定位累积概率分布比较

Fig.11 Comparison of CDF in different algorithms

表 3 不同算法定位误差比较

Tab.3 Comparison of positioning errors in different algorithms

Location algorithm	Max location error /cm	Average location error /cm
CNN	25.02	10.13
Trilateral method	82.03	28.57
SVM	46.22	17.41
DecisionTree	42.43	17.79

5. 结论

本文提出了一种基于 CNN 的室内可见光定位算法。将测量的信号强度 RSS 数据输入到卷积神经网络模型中，确定出精确度更高的预测位置。仿真结果表明，基于 CNN 实现室内定位具有可行性，并可以实现高精度定位；在 5m×5m×3m 的室内环境下，该算法的平均误差为 4.44cm，能够满足大多数室内定位服务的需求。与文中提到的其他定位算法相比，所

提出的定位算法可以实现更精确的定位。此外,基于 CNN 的定位算法易于训练且快速收敛,运用到室内定位场景中值得深入研究。

参考文献

- [1] Basiri A, Lohan E S, Moore T, et al. Indoor location based services challenges, requirements and usability of Current Solutions[J]. Computer Science Review, 2017, 24:1-12.
- [2] Rida M E, Liu F, Jadi Y, et al. Indoor Location Position Based on Bluetooth Signal Strength[C]. 2015 2th International Conference on Information Science and Control Engineering, Shanghai, China. New York: IEEE, 2014: 24-26.
- [3] Liu F, Liu J, Yin Y Q. Survey on WiFi-based indoor positioning techniques[J]. IET Communications, 2020, 14(9):1372-1383.
- [4] Kitamura K, Sanada Y. Experimental Examination of a UWB Positioning System with High Speed Comparators[C]. 2007 IEEE International Conference on Ultra-Wideband, Singapore, 2007: 927-932.
- [5] Bouet M, Santos A L D, Pujolle G. RFID tags: Positioning principles and localization techniques[C]. 2008 1st IFIP Wireless Days, Dubai, United Arab Emirates. New York: IEEE, 2008: 24-27.
- [6] Jovicic A, Li J, Richardson T. Visible light communication:opportunities, challenges and the path to market[J]. IEEE Communications Magazine, 2013, 51(12): 26-32.
- [7] Luo J H, Fan L Y, Li H S. Indoor Positioning Systems Based on Visible Light Communication: State of the Art[J]. IEEE Communications Surveys & Tutorials, 2017, 19(4): 2871-2893.
- [8] Dong W J. High Precision Indoor Visible Light Localization Algorithm[D]. Dalian: Dalian Maritime University,2019:8-13.
董文杰. 高精度室内可见光定位算法研究[D]. 大连: 大连海事大学, 2019:8-13.
- [9] Wang X D, Wu N, Hu Q Q. Indoor visible light positioning based on multiple illuminated areas cooperation [J]. Journal of Optoelectronics·Laser, 2017, 28(4): 388-395.
王旭东, 吴楠, 胡晴晴. 多照明区域协作的室内可见光定位[J]. 光电子·激光, 2017, 28(4):388-395.
- [10] Almaaitah A, Aisaify B, Bani-Hani R. Three-Dimensional Empirical AOA Localization Technique for Indoor Applications[J]. Sensors, 2019, 19(24): 5544.
- [11] Trong-Hop D, Myungsik Y. An in-Depth Survey of Visible Light Communication Based Positioning Systems[J]. Sensors, 2016, 16(5): 678.
- [12] Xu S W, Wu Y, Wang X F. Visible Light Positioning Algorithm Based on Sparsity Adaptive and Location Fingerprinting[J]. Acta Optica Sinica,2020,40(18):1806003.
徐世武, 吴怡, 王徐芳. 基于稀疏自适应和位置指纹的可见光定位算法[J].光学学报, 2020,40(18): 1806003.
- [13] Xu S W, Wu Y, Su G D. Fingerprint Matching and Localization Algorithm Based on Orthogonal Frequency Division Multiplexing Modulation for Visible Light Communication. Laser & Optoelectronics Progress,2019,56(9):090601.
徐世武, 吴怡, 苏国栋. 基于正交频分复用调制的可见光通信指纹匹配算法[J]. 激光与光电子学进展, 2019,56(9):090601.
- [14] Zhuang Y, Hua L C, Qi L N,et al. A Survey of Positioning System Using Visible LED Lights[J]. IEEE Communications Surveys & Tutorials, 2018, 20(3): 1963-1988.
- [15] Dong W J, Wang X D, Wu N. A Hybrid RSS/AOA Algorithm for Indoor Visible Light Positioning [J]. Laser & Optoelectronics Progress, 2018, 55(5): 050603.
董文杰, 王旭东, 吴楠. 基于 RSS/AOA 混合的室内可见光定位算法[J].激光与光电子学进展, 2018, 55(5):050603.

-
- [16] Saadi M, Ahmad T, Zhao Y, et al. An LED based indoor localization system using k-means clustering[C]. 2016 15th IEEE International Conference on Machine Learning and Applications (ICMLA), Anaheim, CA, USA. New York: IEEE, 2016: 246-252.
- [17] Xiao L, Behboodi A, Mathar R. A deep learning approach to fingerprinting indoor localization solutions[C]. 2017 27th International Telecommunication Networks and Applications Conference (ITNAC), Melbourne, VIC, Australia. New York: IEEE, 2017:22-24.
- [18] Huang H Q, Yang A Y, Feng L H, et al. Artificial neural-network-based visible light positioning algorithm with a diffuse optical channel[J]. Chinese Optics Letters, 2017, 15(5): 16-20.



网络首发:

标题: 基于卷积神经网络的室内可见光指纹定位方法

作者: 许浩,王旭东,吴楠

收稿日期: 2020-11-18

录用日期: 2020-12-14

DOI: 10.3788/lop58.1606001

引用格式:

许浩,王旭东,吴楠. 基于卷积神经网络的室内可见光指纹定位方法[J]. 激光与光电子学进展, 2021, 58(16): 1606001.

网络首发文章内容与正式出版的有细微差别, 请以正式出版文件为准!

您感兴趣的其他相关论文:

基于卷积神经网络的驾驶行为分析算法

褚晶辉 张姍 吕卫

天津大学电气自动化与信息工程学院, 天津 300072

激光与光电子学进展, 2020, 57(14): 141018

结合残差学习的尺度感知图像降噪算法

陈欢 陈清江

陕西国际商贸学院基础部, 陕西 咸阳 712046

激光与光电子学进展, 2019, 56(9): 091005

基于正交频分复用调制的可见光通信指纹匹配定位算法

徐世武 吴怡 苏国栋

福建师范大学医学光电科学与技术教育部重点实验室福建省光子技术重点实验室, 福建 福州 350007

激光与光电子学进展, 2019, 56(9): 090601

联合效应影响下脉冲位置调制的大气光多输入多输出系统的误码率

张悦 王惠琴 曹明华 雷景丽 王道斌

兰州理工大学计算机与通信学院, 甘肃 兰州 730050

激光与光电子学进展, 2019, 56(9): 090602

基于深度学习的图像显著区域检测

纪超 黄新波 曹雯 朱永灿 张烨

西安工程大学电子信息学院, 陕西 西安 710048

激光与光电子学进展, 2019, 56(9): 091007