

基于改进 BP-EKF 算法的 SOC 估算

田冬冬¹, 李立伟¹, 杨玉新²

(1.青岛大学 电气工程学院, 山东 青岛 266071; 2.青岛大学图书馆, 山东 青岛 266071)

摘要:准确估测电池当前荷电状态(SOC)是电池储能系统是否安全可靠的重要指标。根据锂电池内部实际动态特性,提出一种改进 BP 神经网络和扩展卡尔曼滤波(EKF)相结合的锂离子动力电池 SOC 估计方法。优化 BP 神经网络前馈分析计算解决传统 BP 信噪比低的问题,将训练成功的改进 BP 神经网络用于补偿 EKF 算法的估计误差,最后在 Matlab/Simulink 上搭建仿真模型进行实验。结果表明,与单纯的 EKF 算法相比,所提出的改进 SOC 估计方法的估算误差在 2%以内,具有良好的矫正性和鲁棒性,能有效提高 SOC 的估计精度。

关键词:荷电状态;改进 BP 神经网络;扩展卡尔曼滤波

中图分类号:TM 912.9

文献标识码:A

文章编号:1002-087X(2020)09-1274-05

DOI: 10.3969/j.issn.1002-087X.2020.09.009

Research on SOC estimation based on improved BP-EKF algorithm

TIAN Dong-dong¹, LI Li-wei¹, YANG Yu-xin²

(1.School of Electrical Engineering, Qingdao University, Qingdao Shandong 266071, China;

2.Library of Qingdao University, Qingdao Shandong 266071, China)

Abstract: Accurate estimation of the battery's current state of charge (SOC) is an important indicator to judge whether the battery energy storage system is safe and reliable. Based on the actual dynamic characteristics of lithium batteries, an SOC estimation method for lithium ion power batteries based on an improved BP neural network and extended Kalman filter (EKF) was proposed. The BP neural network feedforward analysis calculation was optimized to solve the problem of low traditional BP signal-to-noise ratio. The successfully improved BP neural network was used to compensate the estimation error of the EKF algorithm. Finally, a simulation model was built on Matlab/Simulink for experiment. The results show that compared with the simple EKF algorithm, the estimated error of the proposed improved SOC estimation method is within 2%, which has good correction and robustness, and can effectively improve the accuracy of SOC estimation.

Key words: state of charge; improved BP neural network; extend Kalman filter

随着国家电网广泛在电力物联网以及能源互联网战略的提出^[1],可再生能源技术代替传统化石能源的需求日益增强。电动汽车作为一种新型的交通工具,其发展和使用必将逐渐成为一种主流的生活方式。动力电池作为电动汽车的核心,具有相对更好的充电和放电性能,能量比以及高功率承受力^[2]。动力电池相关技术的发展越来越受到人们的重视。但它不同于传统的烃类能源利用特点,电池的当前状态不是直接测量的,需要一系列的状态估计,包括荷电状态(SOC)、健康状态(SOH)、功率状态(SOP)等。同时电池的荷电状态受许多因素的影响,如充放电速率、放电过程、温度等^[3],在各种参数中,锂离子电池的荷电状态的精度和鲁棒性对于电池性能极其重要^[4]。

目前安时积分法是最常用的方法,但是该方法具有开环特性^[5],在电流测量中容易因误差积累而产生发散;开路电压

法广泛应用于电气化车辆蓄电池管理系统中,易于使用,计算速度快,但是最主要问题在于其必须在电池长时间静置达到稳定状态才能进行准确测量估算,因此不适合车辆实际工况运行过程中使用;内阻测量法对测量设备要求高,难以在电动汽车上使用^[6]。EKF 被广泛应用于电池 SOC 的在线估计,但是 EKF 需要精准的电池模型,噪声会造成滤波发散,从而影响 SOC 估计精度。对于 BP 神经网络,其本质是误差反向传播的前馈学习过程,同时校正每层的权重系数,可以减少噪声影响^[7]。

因此本论文提出一种改进 BP 神经网络优化扩展卡尔曼滤波(EKF)的锂离子动力电池 SOC 估计方法,首先通过改进 BP 神经网络前馈分析计算过程,然后将训练成功的改进 BP 神经网络用于补偿 EKF 算法估算 SOC 的误差,使 SOC 估计算法有了更好的自适应性,符合实际运行工况需要^[8]。

1 电池模型选择及参数辨识

1.1 锂离子电池模型

不同的电池等效模型对电池的模拟精确度不同,等效模型中含有 RC 的等效模型精确度较高,且通常 RC 阶数越高其精确度越高,但计算就越复杂,不适用于实时性高、硬件条件

收稿日期:2019-04-15

基金项目:山东省自然科学基金(Y2008F23);山东省科技发展规划项目(2011GGB01123);山东省重点研发计划项目资助(2017GGX-50114)

作者简介:田冬冬(1995—),男,河南省人,硕士研究生,主要研究方向为新能源汽车电控系统。

通信作者:李立伟, E-mail: ytlw@163.com

有限的系统。对于磷酸铁锂电池,通常有 R_{int} 等效模型、Thevenin 等效模型、PNGV 等效模型等。

电池的充放电过程是复杂的非线性动态过程,Thevenin 电池模型即戴维南等效电路,也称为一阶 RC 等效电路。如图 1 所示, R_1 、 C_1 分别为极化内阻、极化电容,用来模拟电池的极化效应, R_0 为电池欧姆内阻, U_{oc} 为电池开路电压, U 为负载电压^[9]。




图1 Thevenin 电池等效模型

Thevenin 电池模型属于一阶非线性模型,设计参数较少,结构简单,在恒流充放电下能保证更好的精度,准确地模拟电池的充放电行为,在 BMS 嵌入式系统里占用资源空间少,优势明显。基于此,本论文将选用 Thevenin 电池等效模型,在 BMS 这样资源有限的嵌入式系统中,其优势将会更加明显,更能精确预测电池的荷电状态。

1.2 参数辨识

在实验室采用容量为 10 Ah 的锂电池模型,搭建电池实验平台,对电池以 1 C 的电流放电 180 s 后再静置 180 s,绘制锂电池的放电规律如图 2 所示。通过曲线可以发现,在放电和停止放电的瞬间,电池电压会有一个瞬间突变,之后再缓慢变化。电压突变是因为电池本身欧姆内阻的存在,如图 2 中 ΔU_1 所示;电压缓慢变化是因为电池内部极化效应的存在^[10],相当于等效模型 RC 环路的零状态响应,如图 2 中 ΔU_2 所示。




图2 锂电池放电曲线参数分析

为测试模型参数进行了 HPPC 脉冲实验,循环放电至要求电压,每次放电量约为 10%。实验结果如表 1 所示。将实验室电池通过确定的模型参数进行放电实验,根据选择的戴维南模型比较,最大误差不超过 4%,模拟电池动态过程准确。

表1 SOC 与各参数对应值

SOC/%	R_1/Ω	R_2/Ω	C/F
90	0.003 763	0.002 311 709	4 309.666 118 0
80	0.003 759	0.002 599 061	3 830.815 805 0
70	0.003 772	0.002 980 729	3 351.965 492 0
60	0.003 775	0.003 476 059	2 873.115 179 0
50	0.003 801	0.004 168 613	2 394.264 866 0
40	0.003 762	0.005 205 396	1 915.414 553 0
30	0.003 791	0.006 927 751	1 436.564 240 0
20	0.003 698	0.010 508 172	957.713 927 3
10	0.003 843	0.021 067 649	478.863 614 4

1.3 SOC-OCV 拟合

为确定与 SOC 值的对应关系,仍将电池进行负荷脉冲实验,读取开路电压,实验中,在 20%~90% 范围内与开路电压密切相关,其数据如表 2 所示。

表2 SOC-OCV 对应值

SOC/%	90	85	80	75	70
电压/V	4.006 8	4.004 8	4.003 2	4.001 5	3.999 5
SOC/%	65	60	55	50	45
电压/V	3.997 2	3.994 5	3.991 4	3.987 6	3.989 2
SOC/%	40	35	30	25	20
电压/V	3.977 1	3.969 7	3.959 7	3.954 8	3.924 8

对此范围内数据进行多项式曲线拟合,公式如式(1):

$$F(SOC_i) = 4.373 \times 10^{-7} SOC_i^3 - 0.000 092 44 SOC_i^2 + 0.006 819 SOC_i + 3.824 \quad (1)$$

经拟合后,曲线和方差为 0.000 024 76,拟合系数为 0.996 4,开路电压与 SOC 关系拟合准确,见图 3。




图3 SOC-OCV 拟合曲线

2 卡尔曼滤波器估算 SOC

2.1 卡尔曼滤波算法

卡尔曼滤波器基本思想是利用信号过程与噪声的状态空间概念,估计随机线性系统状态量在最小均方根误差状态下的最优状态估计值^[11],其离散型状态方程和观测方程见式(2)和式(3):

状态方程:

$$X_{t+1} = A_t X_t + B_t U_t + W_t \quad (2)$$

观测方程:

$$Y_{t+1} = C_t X_t + D_t U_t + V_t \quad (3)$$

式中: X_t 为系统的状态向量,表示 t 时刻估算出的系统状态; U_t 为控制向量,表示 t 时刻外界对系统的控制量; Y_t 为观测向量,表示 t 时刻估算出的测量值; A_t 为状态转移矩阵、 B_t 为控制矩阵、 C_t 为观测矩阵、 D_t 为控制矩阵,由系统结构所确定^[12]; W_t 为过程噪声, V_t 观测噪声,一般是均值为 0 的白噪声,且两者相互独立^[13]。

结合 Thevenin 电池等效模型,在锂电池 SOC 估算中有:

$$SOC(t) = SOC(t_0) - \frac{\int_{t_0}^t dt}{Q_r} \quad (4)$$

$$E(t) = I(t)R_1 + U_C(t) + U_{C0}(t) \quad (5)$$

式中: $E(t)$ 为电池的电动势; $U_C(t)$ 为极化电容的端电压; $U_{C0}(t)$ 和 $I(t)$ 分别为端电压和流过电池的电流,均可通过实验测得; t_0 为初始值; $Q = 1/3 600 Q_N$, Q_N 为标准容量。将其离散化之后,以 SOC、 U_C 为状态变量,以端电压 U 为观测变量的卡尔曼方程为:

$$\begin{bmatrix} SOC_t \\ U_{C,t} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & \exp(-\frac{\Delta t}{R_2 C}) \end{bmatrix} \begin{bmatrix} SOC_{t-1} \\ U_{C,t-1} \end{bmatrix} + \begin{bmatrix} -\frac{\Delta t}{Q_r} \\ R_2(1 - \exp(-\frac{\Delta t}{R_2 C})) \end{bmatrix} I_{t-1} \quad (6)$$

$$U_{C0,t} = E_t - I_t R_1 - U_{C,t} \quad (7)$$

卡尔曼滤波算法是根据某一时刻 SOC 值来计算下一时刻

最小方差意义上的最优 SOC 估计。计算的过程当中能够对精确度控制得很好,并能有效减少外界因素的影响。缺点是需要详细确定电池内部各个参数,但参数难于确定,计算量大。

2.2 扩展卡尔曼滤波器算法

电动汽车锂电池组实际运行过程中,系统是非线性系统的,扩展卡尔曼滤波算法可以通过将非线性系统线性化,使 SOC 估算适应卡尔曼滤波法^[4],其离散化状态公式为式(8)和式(9):

$$X_t = f(X_{t-1}, U_{t-1}) + W_{t-1} \quad (8)$$

$$Y_t = g(X_t, U_t) + V_t \quad (9)$$

式中: X_t 为系统的状态向量; Y_t 为观测向量; $f(X_{t-1}, U_{t-1})$ 和 $g(X_t, U_t)$ 分别为非线性系统的状态转移方程和观测函数^[5]。在 SOC 估算中,对于系统观测函数,每一次预测都要对其围绕状态向量进行泰勒级数展开并省略高阶无穷小量,用来描述 SOC 值与开路电压之间关系得到:

$$U_{CO,t} = \frac{\partial F(SOC_t)}{\partial SOC_t} SOC_t - I(t)R_1 - U_{C,t} \quad (10)$$

结合式(6)用扩展卡尔曼滤波估算 SOC 时,系统得以线性化表示^[6]。

2.3 EKF 估算锂电池 SOC

估算步骤如下:

第一步:状态初始化

$$x_0|_0 = E(x_0), P_0|_0 = E[(x - x_0)(x - x_0)^T] \quad (11)$$

式中: P 为协方差矩阵。

第二步:状态估计

计算 t 时刻的估计值:假设已知前一时刻系统状态值 X_{t-1} 以及电压 U_{t-1} 得到:

$$X_{t|t-1} = f(X_{t-1|t-1}, U_{t-1}) \quad (12)$$

第三步:误差协方差预测

通过计算 $X(t|t-1)$ 的估算误差,求取对应的协方差矩阵:

$$P_{t-1|t-1} = A_{t-1} P_{t-1|t-1} A_{t-1}^T + Q_{t-1} \quad (13)$$

式中: A_{t-1} 为状态转移矩阵; Q_{t-1} 为过程噪声的协方差矩阵。

第四步:卡尔曼增益系数更新

$$K_t = P_t^- C_t^T (C_t P_t^- C_t^T + R_t)^{-1} \quad (14)$$

式中: K_t 为增益系数; C_t 观测矩阵; R_t 为测量噪声的协方差矩阵。

第五步:对状态的更新

根据实时测量获得的开路电压值 U_t 来估算现有的状态的最优估算值:

$$X_{t|t} = X_{t|t-1} + K_t [y_t - g(X_{t|t-1}, U_{t-1})] \quad (15)$$

第六步:根据卡尔曼增益和上一时刻的噪声协方差来更新噪声协方差

$$P_{t|t} = (I - K_t C_t) P_t^- \quad (16)$$

式中: I 为单位矩阵,由式(16)可以看出 K_t 随 P_t 减小而减小,随 R_t 减小而增大,通过算出的增益系数结合 t 时刻的测量值得到系统状态的后验估计^[7],即可求出最优值。随着时间更新方程和测量更新方程的计算,系统状态估计重复进行。

3 基于改进 BP-EKF 算法的电池 SOC 估算

3.1 BP 神经网络算法

BP 神经网络本质上是一个前向反馈学习神经网络,反馈学习贯穿于连接模式结构,主要利用误差的反向传播算法调整每一层神经元对应权值和阈值,实现给定误差函数的最优值。最简单的 BP 神经网络结构为三层结构^[8],其结构图见图 4。




图4 三层BP神经网络

图中 L_A 、 L_B 、 L_C 分别表示输入层、隐含层和输出层。 $\{X_i\}$ 、 $\{Y_i\}$ 、 $\{O_i\}$ 分别表示对应的输出向量, W_{ij} 表示 L_A 层的第 i 个神经元到 L_B 层的第 j 个神经元的传递权值, V_{ij} 表示 L_B 层的第 i 个神经元到 L_C 层第 j 个神经元的传递权值^[9]。

神经网络采用导师训练的方法,BP 神经网络算法的学习过程是前馈学习过程。从本质上说,这是一个误差反向传播的过程,同时校正每层的权重系数。反馈学习包括调整连接模式、每个神经元的权重和阈值以及整个网络的识别。

3.2 改进 BP 神经网络算法

与标准的 BP 神经网络算法相比,本文提出的改进算法主要侧重于前馈计算的改进,主要解决了传统 BP 算法在初始和处理中信噪比低的问题。在预处理阶段增加前馈设计,其主要功能是在去噪时预先判断误差,并在误差超过阈值时提前进行调整。该方法可以从源头上解决错误问题,从而减轻以后过滤的负担。在上述前馈计算中,假设在某样本的前提下,第一个神经元的输入计算公式,见式(17):

$$X_i^n = W_{ij} O_j - \theta_i (i = 1, 2, 3 \dots n) \quad (17)$$

式中: θ 为第一神经元输入层误差。

第二个神经元输出的计算公式见式(18):

$$O_i^n = G(X_i^n) (i = 1, 2, 3 \dots n) \quad (18)$$

式中: $G(X_i^n)$ 为第二个神经元输出映射。

整个系统对应的总输入见式(19):

$$X_k^n = \sum_{i=1}^n W_{ij} O_j^n - \theta_k (k = 1, 2, 3 \dots L) \quad (19)$$

本文每个样本的二次误差的计算公式见式(20):

$$J = 1/2k = 1 \sum_{k=1}^L (t_k^n - O_k^n)^2 \quad (20)$$

式中: J 为二次误差; t 为实际输出。

在前馈计算中,利用优化前馈计算整体改进 BP 神经网络优化权重系数。为了进一步优化整个识别网络, W 的变化与函数在实际变化中的梯度成反比。

修正后的加权公式见式(21):

$$\sigma_k^n = O_k^n (1 - O_k^n) (t_k^n - O_k^n) \quad (21)$$

式中: σ 为加权系数。

对于隐含层函数修改见下式:

$$Z_{ij}(k+1) = Z_{ki}(k) + \delta_i^n O_j^n \quad (22)$$

式中: $Z_{ij}(k+1)$ 为隐含层函数映射。

通过以上改进,与传统的 BP 神经网络算法,增加了权值分割技术,可以解决低信噪比的问题,优化系统识别精度,同时它解决了传统辅助算法的数据大量堆积所造成的弊端。

3.3 改进 BP 神经网络优化 EKF

EKF 线性化过程中,由于噪声滤波影响及误差存在,本文利用改进 BP 神经网络算法的导师训练学习能力对扩展卡尔曼滤波 SOC 估计值进行优化与补偿,降低误差程度,从而将对象模型问题转化为状态参数估测问题,需要将 BP 神经网络的权值、阈值作为输入,扩展卡尔曼滤波器的状态,网络输出作为观测^[9]。算法过程如下:

(1) BP 神经网络算法的训练过程

首先根据选择戴维南等效模型,对实验室的 10 Ah 的磷酸铁锂 18650 型号电池,进行恒流脉冲放电实验,得到训练改进 BP 神经网络所需要的 3 000 组数据。然后对所设计的神经网络进行训练,使采样点训练误差逐渐贴近期望值,当达到预期误差以内时,证明所需的改进 BP 神经网络训练完成。

(2) BP 优化 EKF 算法

首先给出算法的结构如图 5 所示。此算法的实质是,将训练完成的改进 BP 神经网络过程结合到 EKF 算法中,在电池信息不断更新的过程中,进行参数辨识得到准确的模型参数,然后经过扩展卡尔曼滤波器进行滤波处理,将初始数据输入到训练好的改进 BP 神经网络中,得到扩展卡尔曼滤波算法的状态估计补偿,然后计算得到改进 BP 神经网络结合 EKF 的最优状态估计值。

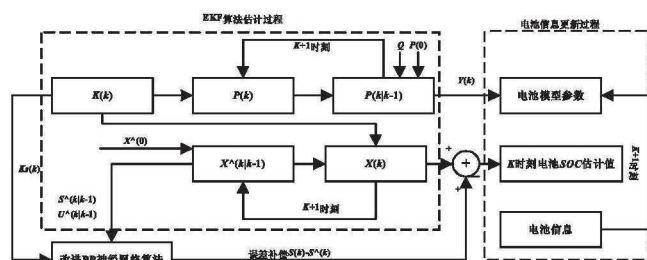


图 5 改进 BP-EKF 流程图

3.4 时间复杂度分析

对于同一个问题,使用不同算法,最终结果可能一致,但在运算过程中消耗的时间资源会有很大区别。时间复杂度是用来描述算法执行时间与数据规模的增长关系,复杂度分析与算法性能测试相比,具有不依赖执行环境、效率高以及指导性强等优势,有利于降低系统开发和维护成本。算法时间量度,通常用数学概念来表示,设定 $T(n)$ 为算法语句的执行次数,问题规模设置为 n ,同时若有某个辅助函数 $f(n)$,当 n 趋近于无穷大时, $T(n)/f(n)$ 的极限为常数且不等于 0,即认为 $T(n)$ 与 $f(n)$ 为同量级函数,即:

$$T(n) = O[f(n)] \quad (23)$$

式(23)为算法的渐进时间复杂度,简称为时间复杂度。

在时间复杂度分析中,通常用大 O 表示法作为算法速度的量值。常见的大 O 运行时间有 $O(\log n)$ 、 $O(n)$ 、 $O(n \times \log n)$ 、 $O(n!)$ 等。对于本论文的改进 BP-EKF 算法,在 3 层 BP 神经网络中,假设每层神经元数量分别为 n_1 、 n_2 、 n_3 ,如果对一个样本进行前馈计算,那么就要进行两次矩阵运算,两次矩阵乘法的本质是向量和矩阵相乘,则分别要进行 $n_1 \times n_2$ 和 $n_2 \times n_3$ 次计算,由于输入层和最终输出层结点数量和是 n_1 和 n_3 确定的,所以可以视为常量,中间的隐藏层数目 n_2 在由自己设定的情况下对一个样本的前馈计算时间复杂度为:

$$O(n_1 \times n_2 + n_2 \times n_3) = O(n_2) \quad (24)$$

同样地在反向传播时时间复杂度和前馈过程计算相同,假设总共有 m 个训练样本,每个样本只训练一次,那么训练一个神经网络的时间复杂度为 $O(m \times n_2)$ 。

4 实验设计及结果分析

4.1 神经网络训练实验

本论文首先利用 Matlab 神经网络工具箱建立 3 层 BP 神经网络,输入层的神经元数量为 4,隐含层神经元数量为 10,输出层神经元数量为 1,最大迭代次数 6 000 次,期望值为 1×10^{-5} ^[20]。将训练改进 BP 神经网络所需要的 3 000 组数据得到的 2 500 组数据输入神经网络中,实验迭代至 2 200 次时达到精度要求,训练完毕^[21]。另外的 500 组数据用来对训练结果进行验证,结果如图 6 所示,




图 6 网络训练采样点对比曲线

神经网络训练采样点测试误差在 1% 以内,如图 7 所示。说明本论文训练完成的神经网络精度较高,可以用于本文改进 BP-EKF 神经网络中^[22]。




图 7 网络训练采样点测试误差

4.2 脉冲放电实验

根据在 Matlab/Simulink 中的 BP 神经网络工具箱,首先将训练完成的 BP 神经网络结构生成 Simulink 网络模块。根据图 5 所示的改进 BP-EKF 流程图构建实验仿真平台^[23]。将 SOC 初始值设置为 100%,实验温度设置为常温状态,电池真实 SOC 值无法直接测量,利用获得的电流、温度、时间等数据通过安时积分法来计算 SOC 理论值^[24]。分别采用改进 BP-EKF 算法

以及 EKF 算法在 Matlab 平台上编程,搭建仿真实验,进行 SOC 估算,并将估算结果与安时积分法进行的 SOC 估算理论值对比。各算法采用的过程噪声 $Q=[1 \times 10^{-9} \ 1 \times 10^{-9} \ 1 \times 10^{-9} \ 1 \times 10^{-8}]$,观测噪声为 $R=0.01$,取初始状态为 $x_0=[0 \ 0 \ 0 \ 1]^T$,状态误差协方差误差为 $P_0=\text{diag}(1,1)$ 。对改进 BP-EKF 和 EKF 算法实验结果如图 8、图 9 所示。




图 8 SOC 实验仿真曲线




图 9 SOC 实验仿真曲线误差

根据脉冲放电仿真实验分析可得,与 EKF 算法相比,BP-EKF 算法,能更快速地实时根据预测值对 SOC 估算值进行快速矫正,稳定在真实值附近,保证实时电池健康状态。

实验对 EKF 和 BP-EKF 算法进行了评价和比较,量化性能比较见表 3。

评价指标	EKF	BP-EKF	%
均方根误差	1.554 053 4	0.644 163 6	
最大误差	3.292 837 6	1.235 916 8	
最大相对误差	5.530 970 0	1.563 580 0	
平均误差	1.351 873 7	0.590 515 4	

从表 3 可以看出,本文改进的 BP-EKF 算法优于传统的 EKF 算法,最大误差可以减小到 2%以内,表明改进算法估计结果具有较高的精度。而当 SOC 估计值收敛到真实值左右时,单独的 EKF 算法的最大相对误差要大很多,约为 5.53%,而采用改进的 BP-EKF 算法的 SOC 估计值的最大相对误差约为 1.56%,比传统估算方法精确度更高,更适合电动汽车 SOC 估算。

5 结论

在实际工况下,精准模型以及噪声影响是 EKF 固有的缺陷,这些降低了它的预测效果,结合 BP 神经网络可以有效地优化这些问题。本论文提出了一种基于改进 BP-EKF 的锂离子电池 SOC 在线估计方法,首先根据锂电池内部实际动态特性,通过优化 BP 神经网络前馈分析计算,构建出改进型 BP 神经网络计算模型,并利用 BP 神经网络辨识的补偿误差值来优化 EKF 估算 SOC。最后仿真实验结果表明,与传统 EKF 算法相比,改进的 BP-EKF 算法估计 SOC 精度在 2%以内,具有

良好的预测和鲁棒性能,能有效提高锂离子电池 SOC 的估计精度,具有较高的工程应用价值,未来会通过其他智能算法对 SOC 估算方法进行优化研究。

参考文献:

- [1] 周美兰,赵强,周永勤.改进的 PSO-BP 神经网络估算磷酸铁锂电池 SOC[J]. 哈尔滨理工大学学报,2015,20(4):88-92.
- [2] 程明,娄柯.基于模型误差 EKF-HIF 算法的锂电池 SOC 联合估计[J]. 四川理工学院学报(自然科学版),2018,31(1):57-63.
- [3] 孔祥创,赵万忠,王春燕.基于 BP-EKF 算法的锂电池 SOC 联合估计[J]. 汽车工程,2017,39(6):648-652.
- [4] 刘小蕊,王顺利,陈明洁,等.基于电路等效和 UKF-EKF 的锂电池 SOC 估算方法研究[J]. 自动化仪表,2018,39(12): 52-55.
- [5] SUN Y, MA Z L, TANG G Y, et al. Estimation method of state-of-charge for lithium-ion battery used in hybrid electric vehicles based on variable structure extended Kalman filter[J]. Chinese Journal of Mechanical Engineering, 2016,29(4): 717-726.
- [6] QIANG J X, AO G Q, YANG L. Estimation method on the battery state of charge for hybrid electric vehicle[J]. Chinese Journal of Mechanical Engineering, 2008, 21(3): 20-25.
- [7] 李义盟,焦朋朋,乔伟栋.基于改进粒子群优化 BP 神经网络的弯道转向行为预测[J]. 公路交通科技,2019,36(10):128-136.
- [8] 荣雅君,杨伟,牛欢,等.基于 BP-EKF 算法的电动汽车电池管理系统 SOC 精准估计[J]. 电工电能新技术,2015,34(9): 22-28.
- [9] 徐艳民.基于 BP-EKF 算法的电池 SOC 估计[J]. 汽车技术,2018(2): 19-23.
- [10] 罗世昌,杨进.基于迭代卡尔曼粒子滤波器的锂电池 SOC 估算算法研究[J]. 工业控制计算机,2019,32(2):104-106.
- [11] BAO H, JIANG W, WEI D. Electric vehicle battery SOC estimation based on EKF[J]. Advanced Materials Research, 2014,3181(1856): 927-931.
- [12] DAI H F, WEI X Z, SUN Z C. Model based SOC estimation for high-power Li-ion battery packs used on FCHVs[J]. High Technology Letters, 2007,13(3): 322-326.
- [13] 赵义群,周晓凤,刘英杰.基于扩展卡尔曼粒子滤波算法的锂电池 SOC 估计[J]. 中国机械工程, 2015(3): 394-397.
- [14] 河海大学常州校区.基于神经网络优化 EKF 的锂离子动力电池 SOC 估计方法: CN201810994346.6[P]. 2018-12-21.
- [15] ZHAO G Q, YAN W Z, TANG S J, et al. A battery management system with a Lebesgue-sampling-based extended Kalman filter[J]. IEEE Transactions on Industrial Electronics, 2019,66(4):3227-3236.
- [16] LAI Y Z, WANG MI W, LAO Z Z, et al. State of charge estimation of lithium-ion batteries using optimized Levenberg-Marquardt wavelet neural network[J]. Energy, 2018,153:694-705.
- [17] 陈磊,周斌.基于 BP 人工神经网络的改进广义预测控制的电网负荷预测[J]. 赤峰学院学报(自然科学版),2019,35(11):62-64.
- [18] 李义盟,焦朋朋,乔伟栋.基于改进粒子群优化 BP 神经网络的弯道转向行为预测[J]. 公路交通科技,2019,36(10): 128-136.
- [19] 和江,彭舒钰,侯文.模糊神经网络 PID 在数字舵机控制中的应用[J]. 计算机测量与控制,2016,24(10):79-81.
- [20] BAO H, JIANG W, WEI D. Electric vehicle battery SOC estimation based on EKF[J]. Advanced Materials Research, 2014,3181(1856): 927-931.
- [21] PASCHERO M, STORTI G L, RIZZI A, et al. A novel mechanical analogy-based battery model for SoC estimation using a multicell EKF[J]. IEEE Transactions on Sustainable Energy, 2016, 7(4): 1695-1702.
- [22] XIE J L, MA J C, BAI K. State-of-charge estimators considering temperature effect, hysteresis potential, and thermal evolution for LiFePO₄ batteries[J]. International Journal of Energy Research, 2018,42(8): 2710-2727.
- [23] HE H W, QIN H Z, SUN X K, et al. Comparison study on the battery SOC estimation with EKF and UKF Algorithms[J]. Energies, 2013,6(10): 5088.
- [24] 杨云龙,徐自强,吴孟强,等.基于免疫遗传算法的动力电池 SOC 估计研究[J]. 计算机测量与控制, 2018, 26(12):220-224.